



## Revisión del Estado del Arte del Proyecto

# Optimización y Desarrollo de Métodos de Inteligencia Computacional Aplicados a la Solución de Problemas en Biomedicina

CIIC 232/2019

Responsable:

Dr. Luis Carlos Padierna García

## Introducción

Un gran número de problemas biomédicos han sido resueltos con técnicas de inteligencia computacional por más de 50 años. Actualmente, estas técnicas siguen en desarrollo y abordando múltiples problemas de interés. La presente revisión explora las técnicas, metodologías, bases de datos y resultados más novedosos respecto a tres ejes principales: Diabetes Mellitus, procesamiento de bioseñales y segmentación semántica de células. La revisión está orientada a cubrir los años 2015 a 2019. Sin embargo, se incluyen también artículos relevantes fuera de este periodo. Los artículos señalados por 2020, estuvieron disponibles desde 2019 en línea. Para cada artículo, se resume su objetivo, metodología, datasets y resultados principales.

1. (Cahn, y otros, 2020) Se estudió el uso de un modelo de aprendizaje automático puede mejorar la predicción de la diabetes utilizando datos de pacientes de registros médicos electrónicos. La **metodología** consistió de un modelo de aprendizaje automático que predice la progresión de pre-diabetes a diabetes utilizando un modelo de árboles impulsados por gradiente. El modelo fue entrenado con **datasets** basados en la base de datos de la Red de Mejora de la Salud (THIN), validado internamente en datos THIN no utilizados para la capacitación y validado externamente en los conjuntos de datos canadienses AppleTree y los Servicios de Salud Maccabi de Israel (MHS). La capacidad predictiva del modelo se comparó con la de un modelo de regresión logística dentro de cada conjunto de datos. Como **resultado** el modelo de aprendizaje automático demostró superioridad sobre el modelo de regresión logística, que se mantuvo en todos los niveles de sensibilidad, comparando AUC [IC 95%] entre los modelos; en el conjunto de datos THIN (0.865 [0.860,0.869] vs 0.778 [0.773,0.784]  $P < .05$ ), el conjunto de datos AppleTree (0.907 [0.896, 0.919] vs 0.880 [0.867, 0.894]  $P < .05$ ) y el Conjunto de datos de MHS (0.925 [0.923, 0.927] vs 0.876 [0.872, 0.879]  $P < .05$ ).

DEPARTAMENTO DE INGENIERÍAS QUÍMICA, ELECTRÓNICA Y BIOMÉDICA  
DIVISIÓN DE CIENCIAS E INGENIERÍAS

Loma del Bosque #103, Col. Lomas del Campestre. León, Gto. C.P. 37150  
Tel. +52 (477) 7 88 51 00 ext. 8522  
lc.padierna@ugto.mx  
www.dci.ugto.mx/depinguim



2. (de Lima, Roque e Lima, & Barbosa, 2020) Se investiga un nuevo algoritmo de selección de características. La **metodología** consistió en la selección de características a través de la máquina de soporte vectorial de doble frontera (FSTBSVM) con kernel RBF. La robustez del FSTBSVM se examina utilizando la precisión de clasificación, el análisis de sensibilidad y la especificidad. Se utilizan ocho **dataset** (BCWO, Diabetic Retinopathy, Pima Indians Diabetes, Immunotherapy, Heart-Statlog, Hepatitis, WDBC y Fertility) que se utilizan comúnmente entre los investigadores que desarrollaron métodos de aprendizaje automático para la clasificación de datos médicos. Los **resultados** muestran que el método propuesto es capaz de producir buenos resultados con menos características que los conjuntos de datos originales.

3. (Rinkel, van der Oest, & Coert, 2020) Investigaron con un árbol de decisión la discriminación de dos puntos estáticos y en movimiento, discriminación de un punto estático y el sentido de vibración para estimar la pérdida sensorial debido a la neuropatía relacionada con la diabetes. Para el **dataset** se emplearon las puntuaciones de la batería de prueba del estudio en 416 pacientes (Estudio formado por características antes mencionadas). La **metodología** consistió en el desarrollo del árbol utilizando los datos de referencia del estudio RDF y validado en los datos de seguimiento y control. Los coeficientes de correlación de Spearman evaluaron la confiabilidad entre el árbol de decisión y el RDF - 39 original. Como **resultado** el árbol redujo el número de elementos de 39 a 3 al estimar el puntaje de suma RDF-39. Las mediciones de M2PD (hallux), S2PD (primera red dorsal, quinto dedo del pie), detección de vibraciones (articulación interfalángica) y S1PD (primera red dorsal, quinto dedo del pie) demostraron ser predictivas. Los coeficientes de correlación con las puntuaciones originales fueron altos (0,76 a 0,91).

4. (Acevedo, Alférez, Merino, Puigvi, & Rodellar, 2019) Se propone utilizar redes neuronales convolucionales (CNN por sus siglas en inglés) y una máquina de soporte vectorial (SVM) para clasificar los elementos presentes en muestras de sangre. Se usó un **dataset** con 17,092 imágenes divididas en ocho clases de células presentes en las muestras de sangre. La **metodología** consiste en utilizar dos CNNs, la VGG-16 e InceptionV3, para extraer las características y posteriormente se añade una SVM para la clasificación. Posteriormente se ajustan los parámetros de las CNNs para llevar a cabo la clasificación añadiendo una capa Soft-Max de activación. Además se usó aumento de datos para balancear el número de imágenes en cada clase. La métrica de evaluación fue *Accuracy*, además se muestra la matriz de confusión. Los **resultados** para el modelo entrenado con el dataset propio obtiene un accuracy de 96.2% y 95% para vgg-16 e InceptionV3, respectivamente. Se lograron valores altos del índice promedio sobre todas las clases, además se toman en cuenta más clases de las que normalmente se utilizan en este tipo de problemas.

5. (Al-Dulaimi, Al-Saabawi, & Resen, 2019) Se propone un método no supervisado al utilizar un algoritmo basado en la distribución de color y texturas, así como un crecimiento adaptativo de región, para contar y segmentar células blancas en muestras de sangre. Se propone mezclar los siguientes **datasets**: Cellavision dataset, del cual se usaron 90 imágenes, ALL-IDB, del cual se usaron 50 imágenes, y *the Wadsworth Centre database*, del cual se usaron 60 imágenes. Como parte de la **metodología** se usa el algoritmo JSEG para cuantizar los colores presentes en cada imagen, posteriormente se mapea la imagen a un espacio de clases (donde cada clase es un color distinto de la



etapa anterior), finalmente se utiliza el algoritmo *Fuzzy C Mean* para realizar la segmentación, acorde a los pixels cercanos a la semilla, y el conteo de células. Las métricas usadas para evaluar al modelo son *Jaccard Distance error*, *Rand Index*, *Boundary Displacement Error* y *F-Index*. En la sección de **resultados** se reportan valores de 0.002, 0.93, 10.11 y 0.93 para las métricas mencionadas en el respectivo orden. Se compararon las métricas contra 13 algoritmos, obteniendo los mejores resultados. También se añaden los resultados en el conteo de células por cada clase.

6. (Fan, y otros, 2019) Se propone modificar una red neuronal convolucional profunda, basada en la Mask-RCNN, para localizar las regiones de interés (ROI) en la imagen y solo segmentar dichas regiones en lugar de hacer la segmentación de la imagen completa, se denominó a esta arquitectura LeukocyteMask. Los **datasets** utilizados son: dataset WBC, el cual contiene dos conjuntos con 100 y 300 imágenes respectivamente, BCISC, el cual contiene 268 imágenes, y LISC, el cual contiene 257 imágenes. Como parte de la **metodología** para la extracción de características se usa una red piramidal de características (FPN por sus siglas en inglés) la cual a su vez está inspirada en la ResNet, posteriormente se usa una modificación de la red de región propuesta (RPN) para localizar las ROIs como un problema binario, finalmente se usan dos ramas paralelas para realizar la predicción final. Las métricas usadas son *Presicion*, *Dice Coefficient*, *mean Intersection Over Union*, *false positive rate*, *false negative rate* y *misclassification error*. Además se utilizó aumento de datos para hacer más robusto el modelo y validación cruzada de cinco pliegues. En la sección de **resultados** se compraron contra tres arquitecturas, incluida la U-Net, así como contra tres versiones de la arquitectura propuesta. LeukocyteMask, utilizando deformaciones elásticas en el aumento de datos, obtuvo en su mayoría los mejores índices en los cuatro datasets.

7. (McKearney & MacKinnon, 2019) Utilizaron una red neuronal profunda para clasificar señales pareadas de respuesta del tronco encefálico a estímulos auditivos. Las señales se clasificaron en: “respuesta clara”, “respuesta inconclusa” y “sin respuesta”. El **dataset** consistió en 232 pares de señales de ocho personas diferentes. Los datos se pueden encontrar en la base de datos PhysioBank. La **metodología** consistió en clasificar todas las señales, después se utilizaron 190 pares para construir una red neuronal que se ajustó utilizando 10-fold cross-validation. Se utilizaron los 42 pares restantes como conjunto de prueba. Como **resultado**, la red neuronal fue capaz de clasificar las señales con una precisión de 92.9%

8. (Parmar, Lakshmanan, Purushotham, & Soundrapandiyan, 2019) Para detectar la retinopatía diabética a tiempo se desarrolló un procedimiento de evaluación el cual consiste en percibir puntos finos de interés, por ejemplo, microaneurismas, a algunos elementos mayores, por ejemplo, exudados, y algunas veces su posición entre sí en imágenes del ojo y después con métodos computacionales predecir la clase para cada una de las imágenes. La **metodología** consistió en clasificar las imágenes en cinco categorías, utilizando redes neuronales convolucionales para el modelo de predicción y se entrena en GPU haciendo uso de la biblioteca acelerada por GPU de primitivas dirigidas a redes neuronales profundas, NVIDIA CUDA Deep Neural Network (cuDNN). Utilizando un **dataset** de 53576 imágenes de retina. El **resultado** es de 85% de precisión.



9. (Biswas, y otros, 2019) Se propone un sistema automatizado basado en aprendizaje profundo (DL) para la detección de luz (para estimar el riesgo de accidente cerebrovascular). La **metodología** se basa en una combinación de dos sistemas DL: codificador y decodificador para la segmentación de la luz. El codificador emplea un modelo de red neuronal de convolución de 13 capas (CNN) para la extracción de características. El decodificador emplea tres capas de muestra de red de convolución total (FCN) para la segmentación de la luz. Se utilizaron tres **datasets** de trazados manuales durante el paradigma de entrenamiento que condujo al diseño de tres sistemas DL. Se implementó el protocolo de validación cruzada para los tres sistemas DL. Para los **resultados** se tomaron tres lecturas de expertos para evaluación. Usando la métrica de la distancia de la polilínea, la estimación de precisión de mérito entre el sistema manual y el sistema DL en más de 407 escaneos estadounidenses fue del 99,61%, 97,75% y 99,89%, respectivamente.

10. (Giannakakis, Trivizakis, Tsiknakis, & Marias, 2019) Se utilizó una red neuronal profunda para identificar diferentes estados de estrés, a partir de electrocardiogramas. El **dataset** que se utilizó consiste en electrocardiogramas de 24 personas (7 mujeres y 17 hombres) de alrededor de 47 años. La **metodología** consistió en preprocesar las señales aplicando diferentes filtros, para después utilizar una red neuronal que clasificara las señales por medio de aprendizaje supervisado. El **resultado** obtenido fue una precisión de 89.8%

11. (Gu, y otros, 2019) Se propone modificar la U-Net utilizando bloques a los que denominan *Dense Atrous Convolution (DAC)* así como el *Residual Multi-kernel Pooling (RMP)*, a la cual denominaron CE-Net. La idea detrás del bloque DAC es extraer información a diferentes escalas cambiando el tamaño del kernel de las capas convolucionales, además se integran caminos paralelos los cuales van variando el número de convoluciones así como la tasa de espacio. En el bloque RMP también se tienen capas de pooling paralelas con distintos tamaños de kernel, las cuales se concatenan a través de una convolución. Cabe señalar que se utilizó como base la ResNet34 para la rama de codificación. Se utilizaron tres **datasets**: ORIGA con 650 imágenes, Messidor con 1,200 imágenes y RIM-ONE-R1 con 169 imágenes, DRIVE con 40 imágenes, LUNA Competition con 534 imágenes, EM Challenge (del ISBI2012) con 30 imágenes, *retinal OCT segmentation* con 20 imágenes en 3D. Como parte de la **metodología** se utilizó el aumento de datos para hacer más robusto al modelo. Se utilizaron distintas métricas, dependiendo de que dataset se evalúa, las cuales incluyen *overlapping error*, *sensitivity*, *accuracy*, *foreground-restricted information theoretic scoring*, *rand Split score*, *rand merge score*, entre otras. Los **resultados** son extensos ya que se compararon distintos algoritmos dependiendo del dataset a segmentar, siendo constante la comparación contra la U-Net original en todos; sin embargo, los mejores índices reportados son obtenidos con la arquitectura propuesta.

12. (Ibtehaz & Rahman, 2019) Se propone modificar los bloques convolucionales de la U-Net original introduciendo un bloque denominado *MultiRes Block*, el cual concatena tres capas convolucionales de 3x3 con la entrada original de cada bloque para obtener información en varias escalas de la misma entrada. Adicionalmente cada capa convolucional tiene un número distinto de filtros para igualar el número de parámetros de la U-Net original, así como capas convolucionales y una conexión residual extra al momento de concatenar las características del codificador con las imágenes de mayor tamaño en el decodificador. Se utilizaron cinco **datasets**: 97 imágenes microscópicas de fluorescencia, 30 imágenes 2D EM images (del ISBI-2012), 2594 imágenes dermoscópicas (del ISIC-2018, ISIC-2017



y HAM10000), 612 imágenes endoscópicas (del CVC.ClinicDB) y 210 imágenes de resonancia magnética (del BraTS17 Competition). Como parte de la **metodología** se compararon los resultados con la U-Net original, y su versión para imágenes 3D la cual se comparó con una versión 3D de la MultiResUnet. Se utilizó la métrica *Jaccard Index* y validación cruzada de 5 pliegues para llevar a cabo los entrenamientos. En términos de porcentajes, los **resultados** obtenidos para cada dataset, siguiendo su aparición en la parte superior, fueron de 91.65, 87.94, 80.29, 82.05 y 78.19, respectivamente. En todos los datasets se obtuvo un mejor resultado contra la U-Net

**13.** (Jia, Liu, & Tai, 2019) Se propone modificar la función de activación (Soft-max) de la U-Net agregando un término que regula espacialmente la segmentación, es por ello que se denomina RU-Net a la arquitectura. Los **datasets** utilizados son: *WBC datasets*, el cual consta de un dataset con 100 imágenes y otro dataset con 300 imágenes. Además se usan los datasets: CamVid el cual consta de videos que se analizan en tandas de imágenes y SUN-RGBD dataset, del cual se seleccionaron 5,285 imágenes al azar. Estos dos últimos no contienen imágenes médicas por lo que omitiremos estos resultados. La **metodología** consta del formalismo matemático para añadir el término regulador en la capa de activación y en la capa ReLU; sin embargo, para los experimentos solo se utiliza la modificación en la función de activación ya que el tiempo de cómputo crece demasiado. Este nuevo término se auto regula a lo largo del entrenamiento durante la etapa de *backpropagation*, lo cual también se demuestra, pero solo se toma una iteración para ajustar este nuevo parámetro para reducir el tiempo de cómputo. Las métricas a evaluar son *Accuracy*, *mean Intersection Over Union* y *Regularization Effect*. Los **resultados** se comparan solo contra la U-Net original, pero se hizo un entrenamiento añadiendo ruido en las imágenes originales. Se demuestra que en todos los casos el modelo propuesto obtiene los mejores índices.

**14.** (Sengür, Akbulut, Budak, & Cömer, 2019) Se propone para un algoritmo obtener la clasificación de células blancas en muestras de sangre. Los **datasets** utilizados se obtuvieron del sitio web Kaggle, el primero contiene 410 imágenes y el segundo contiene 12,500 imágenes, en las últimas se usó aumento de datos. La **metodología** consiste en una combinación de preprocesamiento, obtención de características con una técnica de Deep Learning y un algoritmo basado en la forma, análisis de componentes principales (PCA) y una red neuronal recurrente. Se utilizó la métrica *Accuracy* para evaluar las clasificaciones. En la sección de **resultados** se obtiene un 85.7% de accuracy, también se reporta la matriz de confusión donde se explica el rendimiento de clasificación de cada clase.

**15.** (Wollmann, y otros, 2019) Se propone utilizar la forma de la U-Net agregando el refinamiento iterativo de las características aprendidas a través de unidades recurrentes cerradas (GRU por sus siglas en inglés); además se propone agregar unidades densas de resolución completa (FRDU por sus siglas en inglés), combinadas con capas de pooling y unpooling para combinar las características de las GRU y obtener la segmentación. Es por ello que se denomina a esta arquitectura GRUU-Net. Se usaron varios **datasets**: 50 imágenes de células de glioblastomas y el Cell Tracking Challenge el cual contiene un gran conjunto de imágenes de diferentes problemas. Se pueden consultar los detalles en el artículo. Como parte de la **metodología** se utilizó aumento de datos para hacer más robusto al modelo, las métricas que se consideran para evaluar las segmentaciones son *Dice Coefficient*, *Jaccard Index* y *Hausdorff Distance*. En la sección de **resultados** se compara la GRUU-Net contra cuatro algoritmos,





así como tres versiones de la U-Net y la ASPP-Net. Puesto que se reportan las métricas para cada tipo de imagen en el segundo dataset, se omite escribir todos los índices; sin embargo, se reporta que el modelo propuesto obtiene los mejores resultados en la mayoría de los subconjuntos.

**16.** (Zhou, Wang, Li, & Zhang, 2019) Se propone un método denominado umbral de histograma adaptativo (AHT por sus siglas en inglés) el cual primero segmenta el núcleo de la región de interés (ROI), posteriormente localiza el citoplasma para obtener la segmentación final. Se usa un **dataset** con 60 imágenes con tinción estándar. En la **metodología** se dan los detalles acerca de la combinación del espacio de color HSI y canales RGB, así como el criterio de actualización de los pesos de cada componente, para lograr segmentar los núcleos. Para segmentar el citoplasma se usa *median filter* en escala de grises y se dan detalles de la actualización de umbrales. Las métricas usadas son *Misclassification Error (ME)*, *false positive rate (FPR)*, *false negative rate (FNR)* y *kappa index (KI)*. Se compara contra otros dos algoritmos en la sección de **resultados**, obteniendo 0.048, 0.051, 0.038 y 0.944 para ME, FPR, FNR y KI respectivamente. Estos valores fueron los mejores evaluando la segmentación total, también se midieron las métricas para evaluar la segmentación del núcleo y el método propuesto obtuvo los mejores resultados (excepto en FPR) comparando con los otros dos métodos.

**17.** (Zeng, Xie, Zhang, & Lu, 2019) Se propone una arquitectura basada en la U-Net a la que se añaden bloques residuales y mecanismos de canales y escalas múltiples, por lo que se nombró como RIC-Unet por las siglas *Residual-Inception-Channel attention U-Net*. Se utilizó el **dataset** TCGA, el cual contiene 30 imágenes con tamaño 1,000 x 1,000 de siete distintos órganos. Como parte de la **metodología** se usan bloques RI en la rama de codificación y en la rama decodificadora se utiliza la metodología propuesta en la U-Net original añadiendo bloques que preservan la información de características de baja resolución. Adicionalmente se hizo un preprocesamiento de las imágenes y un postprocesamiento para mejorar la segmentación obtenida. Para reportar los **resultados** se utilizaron las métricas *F1 Score*, *Dice Coefficient* y *Jaccard Index*. Obteniendo valores de 0.8278, 0.8008 y 0.5635, respectivamente, los cuales fueron los mejores valores comparados con 3 algoritmos previos y 3 versiones de la U-Net

**18.** (Acharya, y otros, Automated identification of shockable and non-shockable life-threatening ventricular arrhythmias using convolutional neural network, 2018) Se creó una red neuronal convolucional para clasificar electrocardiogramas de 2 segundos de duración en ritmos desfibrilables y no desfibrilables. El **dataset** que se utilizó fueron 3 bases de datos públicas: MITDB (48 señales), VFDB (22 señales) y CUDDB(35 señales). La **metodología** consistió en entrenar una red neuronal de 11 capas de convolución para clasificar los electrocardiogramas. El **resultado** obtenido fue un modelo con precisión de 93.18%, sensibilidad de 95.32% y especificidad de 91.04%

**19.** (Acharya, y otros, Deep Convolutional Neural Network for the Automated Diagnosis of Congestive Heart Failure Using ECG Signals, 2018) Se creó una red neuronal convolucional para el diagnóstico de insuficiencia cardíaca a través de electrocardiogramas. El **dataset** que se utilizó consiste en electrocardiogramas de bases de datos públicas encontradas en PhysioBank: BIDMC, Congestive Heart Failure Database, Fantasia Database y NSRDB. La **metodología** consistió en entrenar una red neuronal de 11 capas de convolución para clasificar los electrocardiogramas. El **resultado** obtenido fue un modelo con precisión de 98.97%, sensibilidad de 98.87% y especificidad de 99.01%



20. (Acharya, y otros, 2018) Se utilizó una red neuronal profunda para detectar cuadros de depresión a partir de encefalogramas. El **dataset** que se utilizó consiste en encefalogramas de 15 personas con depresión y 15 personas normales. La **metodología** consistió en utilizar una red neuronal con 5 capas de convolución, 5 capas de pooling y 3 capas totalmente conectadas. El **resultado** obtenido fue una precisión de 93.5% para señales provenientes del hemisferio izquierdo y de 96.0% para las señales del hemisferio derecho.

21. (Alom, Yakopcic, Taha, & Asari, 2018) Se propone una modificación de la U-Net original, añadiendo bloques recurrentes a las capas convolucionales y concatenando la entrada a cada bloque con su respectiva salida de manera residual, es por ello que se nombró R2U-Net a la arquitectura. El **dataset** utilizado fue el *2018 Data Science Bowl Grand Challenges*, el cual contiene 735 imágenes. Como parte de la **metodología**, se usan 650 imágenes para entrenar al modelo, de las cuales el 20% se utiliza para validación, y las 65 restantes se utilizan como prueba. Se utilizaron las métricas *Dice Coefficient* y *Mean Squared Error*. En la sección de **resultados** se reporta un valor del 92.15% para *Dice Coefficient*

22. (Chen, y otros, 2018) Desarrollaron una arquitectura de machine learning para investigar el valor discriminante del método de perfusión entre pacientes con diabetes mellitus tipo y controles normales, el patrón de red relacionado con DM2, y la asociación del patrón con el rendimiento cognitivo/severidad de la enfermedad. Emplearon un **dataset** de 73 sujetos (41 pacientes DM2 y 32 controles) de entre 50-85 años de edad como referencia, y 42 sujetos (19 DM2 y 23 controles) de entre 53-88 años de edad bajo seguimiento por 2 años. La **metodología** seguida consistió en emplear PCA, extracción de características y un clasificador de regresión logística para generar la red de patrón relacionada con DM2. Sus **resultados** indican que el método de machine learning es superior a la comparación univariada de grupo bajo los índices de accuracy, ROC, valor predictivo positivo de prueba y R cuadrada de McFadden ajustada.

23. (Haenssle, y otros, 2018) Se evaluó el uso de redes neuronales convolucionales para la detección de melanoma. El **dataset** fueron 100 imágenes dermoscópicas junto a sus correspondientes diagnósticos. La **metodología** consistió en utilizar la arquitectura “Google’s Inception v4”. Una vez la red neuronal fue entrenada se midió la sensibilidad, especificidad y área bajo la curva para clasificar los diagnósticos. Los resultados se contrastaron con la opinión de un grupo internacional de 58 dermatólogos. También se comparó con los 5 mejores algoritmos del concurso ISBI 2016. Como **resultado** se obtuvo una sensibilidad y especificidad de 86.6% y 71.3% para el nivel I. Después de proporcionar más información clínica la sensibilidad aumentó a 88.9% y la especificidad a 75.7%. La red neuronal obtuvo resultados cercanos a los mejores 3 algoritmos del concurso ISBI 2016.

24. (Smitha, Nisa, & Archana, 2018) El microaneurisma (MA) es el primer síntoma clínico de la retinopatía diabética, La **metodología** propuesta se basa en la implementación de una red neuronal artificial (ANN) que se utiliza como clasificador y se comparan contra el clasificador Naïve Bayes detecta. Los parámetros de prueba se calculan con el **dataset** ROC y también en el conjunto de datos E-optha EX de los cuales la imagen preprocesada, se seleccionan las regiones máximas locales. Los



perfiles de sección transversal de los píxeles seleccionados se registran y analizan. El paso de detección de picos termina dando una imagen preprocesada establecida. Los **resultados** son NB 80.9, ANN 83.3 y NB 80.9, ANN 88.09 respectivamente.

**25.** (Abdullah, Gayathri, Selvakumar, & Kumar, 2018) Este trabajo de investigación se centra en la aplicabilidad de los clasificadores de la máquina de vectores de soporte (SVM) para predecir el riesgo relacionado con la diabetes tipo II. La **metodología** implica el despliegue de varias funciones del núcleo en la construcción de modelos SVM. El **dataset** utilizado es Diabetes del repositorio UCI. Los **resultados** experimentales muestran que la clasificación de datos usando SVM sobre la función variada del núcleo tiene una mejora sobre la precisión con 86.65%, precisión 76.21% y recuperación con 81.11% respectivamente. Entre los núcleos experimentados, el núcleo polinomial se desempeñó mejor que los otros núcleos con mayores resultados de correlación.

**26.** (Adam, y otros, 2018). Caracterizan pies diabéticos para su posterior clasificación empleando una cámara de infrarrojo. Como **dataset** emplearon termogramas de la planta del pie de 33 personas sanas y 33 individuos con diabetes tipo 2. Su **metodología** consistió en emplear transformada wavelet discreta y técnicas de alto orden espectral, además emplearon características de entropía y textura para la caracterización. Como clasificador emplearon Máquinas de soporte vectorial. Sus **resultados** indican una exactitud máxima de 89.39%, con sensibilidad de 81.81% y especificidad de 96.97% usando sólo 5 características.

**27.** (Marin, y otros, 2018) Esta investigación tiene como objetivo presentar la metodología y los primeros resultados de un sistema de detección de riesgo de edema macular diabético (EMD) en imágenes de fondo de ojo. El sistema se basa en la detección de exudados retinianos (Ex), cuya presencia en la imagen se utiliza clínicamente para un diagnóstico precoz de la enfermedad. La **metodología** está basada en aplicar algoritmos de procesamiento de imagen digital a la imagen retiniana para obtener un conjunto de regiones candidatas para ser Ex, que se validan mediante extracción de características y técnicas de clasificación supervisadas. Las imágenes se obtuvieron del **dataset** MESSIDOR en el cual se tiene una muestra de 1058 imágenes de fondo de ojo correspondientes a 529 pacientes con diabetes. Los **resultados** lograron un nivel de sensibilidad comparable al de los especialistas oftalmológicos: logró una sensibilidad de 0.9000 por paciente contra 0.7733, 0.9133 y 0.9000 de varios especialistas, donde los falsos negativos fueron casos clínicos leves de la enfermedad. Además, el nivel de especificidad alcanzado por el sistema fue de 0.6939, lo suficientemente alto como para detectar aproximadamente el 70% de los pacientes sin evidencia de EMD.

**28.** (Mohsen, El-Dahshan, El-Horbaty, & Salem, 2018) Se utilizó una red neuronal profunda para clasificar imágenes provenientes de resonancias magnéticas en 4 categorías distintas, para detectar tumores cerebrales. El **dataset** consiste en 66 imágenes de resonancias magnéticas de diferentes cerebros. La **metodología** consistió en utilizar un algoritmo conocido como C-means difuso para segmentar las imágenes, después extraer características utilizando una transformada wavelet y una técnica conocida como PCA. Finalmente se clasificaban las imágenes utilizando la red neuronal profunda. Como **resultado**, se obtuvo un modelo eficiente con buenas evaluaciones en las métricas convencionales.





**29.** (Xheng, Wang, Guang, & Liu, 2018) Proponen un método no supervisado para la segmentación y clasificación de células blancas en muestras de sangre utilizando. Se utilizan dos **datasets**, el primero con 100 imágenes y el segundo con 300 imágenes. En la **metodología** se especifican los algoritmos propuestos. Primero se retira el fondo utilizando agrupamiento por *K-means*, posteriormente se recupera el área de interés mediante un análisis de concavidad (lo cual retira las células rojas adyacentes a las células blancas). Posteriormente se extraen las características y se clasifica cada imagen utilizando una máquina de soporte vectorial (SVM). Las métricas usadas para evaluar los resultados son *over segmentation rate*, *under segmentation rate*, *overall error rate*, *relative distance error*. En la sección de **resultados** se muestra la mejora en el proceso de segmentación en cada etapa del algoritmo. Los valores reportados de las métricas en su mayoría son los mejores, comparados contra cuatro algoritmos (incluida la U-Net). A su vez se reporta el tiempo promedio por segmentación en la etapa de evaluación, el cual es el menor de todos los algoritmos (90 ms para el dataset 1 y 630 ms para el dataset 2)

**30.** (Zeng, Chen, Zhang, Bai, & Han, 2018) Se propone una modificación de la U-Net en la cual se conectan a pares las capas convolucionales usando una capa de *batch normalization*, así como una capa ReLU, terminando con una concatenación de dos capas convolucionales. Por este motivo se le denominó Dense-U-Net a esta arquitectura. Los **datasets** utilizados son: ISBI 2012 con 30 imágenes, Glioblastoma-astrocytoma U373 con 34 imágenes y HeLa con 18 imágenes. Como parte de la **metodología** se utilizaron las métricas *Accuracy*, *foreground-restricted rand scoring* y *foreground-restricted information theoretic scoring*. Obteniendo como **resultados** mejores valores para los tres datasets, los cuales se compararon contra tres algoritmos (incluida la U-Net). Siguiendo los datasets mencionados, se obtuvieron los valores (96.62%, 0.7412, 0.9206), (99.54%, 0.9950, 0.9874) y (98.28, 0.6017, 0.5725) para accuracy, rand scoring e information theoretic scoring, respectivamente, para cada dataset. Cabe señalar que fueron los mejores valores de los cuatro algoritmos evaluados.

**31.** (Abbas, Fondon, Sarmiento, Jiménez, & Alemany, 2017) En este artículo, se desarrolla un novedoso sistema de reconocimiento automático para los cinco niveles de gravedad de la retinopatía diabética (SLDR). La **metodología** utilizada se basó principalmente en el aprendizaje de características profundas, para esto se utiliza un algoritmo de aprendizaje profundo multicapa semi-supervisado junto con una nueva capa comprimida y pasos de ajuste. Este sistema SLDR se evaluó y comparó con técnicas de vanguardia utilizando las medidas de sensibilidad (SE), especificidad (SP) y área bajo las curvas operativas receptoras (AUC). Los **datasets** empleados fueron DIARETDB1, FAZ, MESSIDOR, HUPM, Prv-DR. El **resultado** de este sistema SLDR se evaluó y comparó con técnicas de vanguardia utilizando las medidas de sensibilidad (SE), especificidad (SP) y área bajo las curvas operativas receptoras (AUC). En 750 imágenes de fondo de ojo (150 por categoría), se obtuvieron en promedio el SE del 92.18%, el SP del 94.50% y el AUC de 0.924 valores.

**32.** (Dasgupta & Singh, 2017) Se utilizó una red neuronal para segmentar automáticamente imágenes de vasos sanguíneos de la retina. Se utilizó un **dataset** conocido como DRIVE que consiste en imágenes de 400 pacientes distintos con diabetes de entre 25 y 90 años junto con sus máscaras de segmentación. La **metodología** consistió en preprocesar las imágenes extrayendo el canal verde de la imagen para después normalizarla. Una vez procesadas las imágenes se entrenó una red neuronal con 7 capas de convolución. El **resultado** que se obtuvo fue un modelo con 95.33% de precisión.



33. (Esteve, y otros, 2017) Se creó una red neuronal para clasificar de manera automática casos de cáncer o lesiones en la piel, a través de imágenes junto con su respectivo diagnóstico. El **dataset** lo conformaron 129,450 imágenes etiquetados con el diagnóstico correcto. En la base de datos se encuentran imágenes con 2,032 enfermedades diferentes. Como **metodología** se utilizó una arquitectura conocida como “GoogleNet Inception v3” que fue entrenada previamente con aproximadamente 1.28 millones de imágenes del concurso “2014 ImageNet Large Scale Visual Recognition Challenge”, después se entrenó para el dataset particular utilizando aprendizaje transferido. Como **resultado**, se logró crear un modelo que tiene una precisión del mismo nivel que un grupo de 21 dermatólogos certificados.

34. (Kang, Min, & Ye, 2017) Se utiliza una red convolucional profunda para interpretar de mejor manera imágenes provenientes de tomografías con un bajo nivel de rayos X. El **dataset** consiste en 2304 imágenes de 10 pacientes diferentes. Este dataset fue parte del concurso “CT low-dose Grand Challenge” del 2016. La **metodología** consiste en entrenar un modelo que se aplique sobre los coeficientes de la transformada wavelet de tomografías de dosis bajas. Como **resultado** se obtuvo un modelo que es además de ser capaz de remover patrones complejos de ruido presentes en las tomografías, es un método eficiente.

35. (Nakajima, y otros, 2017) Se creó una red neuronal para ayudar a diagnosticar casos de cardiopatía isquémica. El **dataset** consiste en 1001 imágenes de 12 hospitales. La **metodología** consistió en entrenar una red neuronal que clasifique áreas potencialmente anormales como verdaderas o falsas. Después se compararon los resultados contra la opinión de 364 expertos diferentes. Como **resultado** se obtuvo un modelo capaz de obtener mejores resultados que los métodos convencionales.

36. (Rajpurkar, Hannun, Haghpahani, Bourn, & Ng, 2017) Se utilizó una red neuronal para detectar una amplia variedad de arritmias a través de electrocardiogramas. El **dataset** consistió en 64,121 electrocardiogramas de 29,163 pacientes diferentes. Cada uno de los electrocardiogramas abarca 30 segundos. La **metodología** consistió en entrenar una red convolucional de 34 capas para después comparar sus resultados contra la opinión de 6 cardiólogos diferentes. Como **resultado**, se obtuvo un modelo que que mejoró tanto en sensibilidad como en precisión al promedio de los cardiólogos.

37. (Ramachandran, Hong, Sime, & Wilson, 2017) En este estudio se investiga la posibilidad de que una red neuronal profunda pueda detectar retinopatía diabética. La **metodología** se basa en la curva característica operativa del receptor para ilustrar la capacidad de una red neuronal profunda para identificar la retinopatía diabética referible (retinopatía diabética moderada o peor o exudados dentro del diámetro de un disco de la fovea). El **dataset** se conforma de fotos de la retina diabética de la base de datos de Otago fotografiadas durante octubre de 2016 (485 fotos) y 1200 fotos de la base de datos internacional de Messidor. Los **resultados** dados por la red neural profunda tuvieron un área bajo la curva característica operativa del receptor de 0.901 (intervalo de confianza del 95% 0.807-0.995), con sensibilidad del 84.6% y especificidad del 79.7% para Otago y 0.980 (intervalo de confianza del 95% 0.973-0.986 ), con una sensibilidad del 96.0% y una especificidad del 90.0% para Messidor.

38. (Tan, Acharya, Bhandary, Chua, & Sivaprasad, 2017) Se utilizó una red neuronal convolucional para segmentar, de manera automática y simultánea, vasos sanguíneos, fovea y disco óptico. El **dataset** que se utilizó fue una base de datos pública conocida como DRIVE. La base de datos contiene imágenes



de 400 pacientes distintos con diabetes de entre 25 y 90 años. La **metodología** consistió en utilizar una red neuronal convolucional de 7 capas que segmentara las imágenes. El **resultado** obtenido fue un modelo con una precisión de 92.68%

39. (Tan, y otros, 2017) Se utilizó una red neuronal convolucional para segmentar, de manera automática y simultánea, exudados, micro-aneurismas y hemorragias. El **dataset** que se utilizó fue una base de datos pública conocida como CLEOPATRA. De esta base de datos, 149 imágenes fueron utilizadas para entrenar y 149 para probar la red neuronal. La **metodología** consistió en utilizar una red neuronal convolucional de 10 capas que segmentara las imágenes. El **resultado** obtenido fue un modelo con una precisión de 87.58% para exudados y de 71.58% para lesiones oscuras.

40. (Xia & Kulis, 2017) Se propone una arquitectura en forma de W, utilizando dos U-Nets concatenadas, para formar un modelo no supervisado el cual no requiere etiquetas previas para lograr la segmentación. El **dataset** utilizado para el entrenamiento fue el *PASCALVOC2012*, el cual contiene 11,530 imágenes (de las cuales solo 6,929 están segmentadas). La **metodología** consiste en obtener una primera segmentación con la U-Net que codifica la imagen y posteriormente refinar dicho resultado con la segunda U-Net. Se utilizaron los datasets BSDS300 y BSDS500, con 300 y 500 imágenes respectivamente, para evaluar la segmentación obtenida. Los **resultados** obtenidos se evaluaron a través de las métricas *Variation of Information*, *Probabilistic Rand Index* y *Segmentation Covering*. Se reportaron los valores utilizando *Optimal Dataset Scale (ODS)* y *Optimal Image Scale (OIS)* para cada métrica. Se obtuvieron parejas de valores para cada métrica, correspondientes al ODS y OIS, de (0.60, 0.65), (0.82, 0.86), (1.63, 1.45) para el dataset BSDS300 y (0.59, 0.64), (0.82, 0.85), (167, 147) para el dataset BSDS500. Los cuales se compararon contra 7 algoritmos para cada dataset.

41. (He, Zhang, Ren, & Sun, 2016) Proponen una red profunda añadiendo conexiones directas entre la entrada y salida en las capas convolucionales, a la cual se nombró ResNet. Se probó la arquitectura con **dataset** ImageNet2012 *classification dataset*, el cual consiste en 1,000 clases en más de 1.28 millones de imágenes. Como parte de la **metodología** se hicieron varias pruebas con la arquitectura, variando el número de capas, además de utilizar un modelo sin conexiones residuales. Posteriormente se utilizó el dataset CIFAR-10, el cual contiene 60,000 imágenes de 10 clases para comparar el modelo propuesto. Como **resultado** se obtuvo un error de clasificación del 6.43%, para la ResNet con 110 capas. Se comparó el modelo contra diferentes versiones de la propia ResNet, así como otros 6 trabajos previos.

42. (Milletari, Navab, & Ahmadi, 2016) Se propone un modelo supervisado el cual es una generalización de la U-net para procesar imágenes médicas volumétricas, aunque la arquitectura base es la misma se cambian los kernels de las capas convolucionales para extraer información en tres dimensiones. El **dataset** contiene 80 imágenes de resonancia magnética de próstata, el cual forma parte de *PROMISE2012 challenge dataset*. Como parte de la **metodología** se utilizó aumento de datos para hacer más robusto el modelo, utilizando 50 imágenes para el entrenamiento, al final de la capa *softmax* se consideran los valores mayores a 0.5 como parte de la segmentación. Se utilizó un *momentum* de 0.9, un *learning rate* de 0.0001. Los **resultados** se evaluaron en términos de las métricas *Dice Coefficient*, *Hausdorff Distance* y el valor obtenido en el *challenge data*, obteniendo valores de 0.869, 5.71 y 82.39, respectivamente. Estos valores son similares a los obtenidos por otros algoritmos, obteniendo un menor tiempo de cómputo.



43. (Prakash, Hemalakshmi, & Mary, 2016) Este artículo presenta un método para la detección y clasificación de exudados en imágenes retinianas coloreadas. Elimina la región de exudados de replicación al eliminar la región del disco óptico. La **metodología** de esta investigación se centra en la detección del disco óptico es indispensable para este enfoque que ha sido detectado por las técnicas de agrupación Kmeans de la Región de interés (ROI). Los exudados se encuentran utilizando su alta variación de nivel de gris, y la clasificación de los exudados se realiza con características de exudados y clasificador SVM. El sistema propuesto se valora y prueba con el **dataset** e-Opha-Ex disponible públicamente. Dentro de los **resultados** los exudados se clasificaron como exudados verdaderos o falsos con la ayuda del clasificador SVM y pudieron distinguir entre cuatro tipos diferentes de nivel de calificación con una precisión promedio de 94.17%.

44. (Kim, Kim, Kwak, & Baja, 2017) En este estudio se prueba la utilizad de una red neuronal profunda (DNN) para predecir la DM2. La **metodología** fue el seleccionamiento de 96, 214, 399 y 678 polimorfismos de un solo nucleótido (SNP) a través de la prueba exacta de Fisher y la regresión logística penalizada por L1. Además de dividir cada conjunto de datos al azar en 4: 1 para entrenar modelos de predicción y probar su rendimiento. El **dataset** que se utilizó se basó en el estudio de casos y controles anidados del Estudio de salud de enfermeras (3326 mujeres, 45.6% de DM2) y el Estudio de seguimiento de profesionales de la salud (2502 hombres, 46.5% de DM2). En los **resultados** el DNN y las regresiones logísticas mostraron mejor área bajo la curva (AUC) de las curvas ROC que el modelo clínico cuando se incluyeron 399 o más SNP. El DNN fue superior a las regresiones logísticas en AUC con 399 o más SNP en hombres y 678 SNP en mujeres. La adición de factores clínicos aumentó constantemente el AUC de DNN pero no logró mejorar las regresiones logísticas con 214 o más SNP.

45. (Naranjo, Pérez, Martín, & Campos-Roca, 2017). Estudian la presencia de la enfermedad de Parkinson con base en la información obtenida por biomarcadores acústicos. **Metodología:** emplearon reducción de variables basada en correlación y regresión bajo el enfoque LASSO. El **dataset** consta de 80 individuos mayores a 50 años. 40 de ellos sanos (22 hombres y 18 mujeres) y 40 afectados por la enfermedad de Parkinson (27 hombres y 13 mujeres). Sus **resultados** indican 86.2% de exactitud, 82.5% de sensibilidad y 90% de especificidad.

46. (Cogil & Wang, 2016) El objetivo es seleccionar de un conjunto de genes, aquellos que sean candidatos de riesgo a desarrollar enfermedades del espectro autista. En su **metodología** utilizan máquinas de soporte vectorial en su versión de clasificación. Después de entrenar la MSV, utilizan los valores numéricos de los vectores soporte para ponderar cada uno de los genes analizados. El **dataset** utilizado consta de 524 ejemplos con un rango de tiempo de desarrollo desde 8 semanas de concepción hasta los 40 años, a partir de 26 estructuras cerebrales. Sus **resultados** indican un 76.7% de exactitud promedio, 77.2% de especificidad y 74.4% de sensibilidad.

47. (Gill & Mittal, 2016) El objetivo de este estudio es proponer un modelo computacional de predicción híbrida (HPM) para la predicción eficiente de la diabetes. La **metodología** utilizada se dividió por etapas, en la primera etapa de la HPM propuesta, el método de selección de características de filtración de MATLAB se utiliza para seleccionar los predictores más discriminatorios, lo que refleja la posibilidad de aparición de diabetes. En la segunda etapa, se aplica una clasificación de dos capas en los datos filtrados, combinando la máquina de vectores de soporte (SVM) y la red neuronal, para mejorar la tasa de reconocimiento general del modelo. El **dataset** Pima se utiliza como fuente de datos,





obtenida de la Universidad de California, Irvine (UCI), el repositorio de aprendizaje automático. El **resultado** fue debido al modelo híbrido propuesto ganó el 96.09% de precisión general.

**48.** (Spanhol, Oliveira, Petitjean, & Laurent, 2016) Presentan una base de imágenes microscópicas con el fin de estudiar si ciertos tejidos de tumores en pecho son evidencia de ser benigno o maligno. En su **metodología** para extracción de características y clasificación utilizan el método de Patrón binario local completo, local phase quantization, matrices de co-ocurrencia en niveles de grises y estadísticas de umbral de adyacencia, entre otros. Como clasificadores emplearon k-NN, Máquinas de soporte vectorial y random forest. El **dataset** consta de 7909 imágenes de cáncer de pecho histopatológico adquirido de 82 pacientes. Incluye imágenes de casos benignos y malignos. Sus **resultados** indican una exactitud entre 80 y 85%

**49.** (Kaur & Kaur, 2015) Los exudados son lesiones brillantes que se consideran un signo primario de la retinopatía diabética, en este artículo, se propone un enfoque híbrido para la detección automática de exudados de imágenes de fondo de ojo. La **metodología** utilizada para el preprocesamiento utiliza el enmascaramiento de enfoque, la segmentación basada en la región se usa para la detección de candidatos y luego la clasificación basada en píxeles se usa para determinar el nivel de gravedad de la enfermedad. El método propuesto prueba el nivel de imagen y el nivel de píxel en **dataset** DIARETDB1 disponible públicamente que contiene 89 imágenes de fondo de ojo totales y da como **resultado** una especificidad de 98.12% y una sensibilidad de 90.83% considerando la evaluación de nivel de píxel, mientras que es 86.04% 91.06% respectivamente en evaluación a nivel de imagen

**50.** (Muthu Rama, y otros, 2015) En este trabajo, se propone la clasificación automatizada de DME utilizando espectros de orden superior (HOS) de proyecciones de transformación de radón de las imágenes de fondo. La **metodología** está desarrollada en base al análisis discriminante de regresión espectral (SRDA) reduce la dimensión de la característica y se utiliza el método de relevancia mínima de máxima redundancia para clasificar los componentes SRDA significativos. Las características clasificadas se alimentan a varios clasificadores supervisados, a saber, Naive Bayes, AdaBoost y máquina de soporte vectorial, para discriminar No DME, NCSME y clases de edema macular clínicamente significativas. El rendimiento de nuestro sistema se evalúa utilizando el **dataset** MESSIDOR disponible públicamente (300 imágenes) y también se verifica con un conjunto de datos local (300 imágenes). El **resultado** nos deja ver que los componentes SRDA de los acumuladores de HOS de tercer orden junto con NB proporcionaron el AUC promedio más alto de 0.9692 y 0.9750 para los conjuntos de datos MESSIDOR y locales, respectivamente.

**51.** (Ronneberger, Fischer, & Brox, 2015) Propusieron una arquitectura supervisada, a la cual denominaron U-Net, basada en técnicas de Deep Learning, específicamente en redes neuronales convolucionales, para realizar segmentación semántica de imágenes de índole médico. Se utilizaron tres **datasets**; el primero contiene 30 imágenes del *EM segmentation challenge*, el segundo contiene 35 imágenes y es parte del *ISBI cell tracking challenge 2014 and 2015*, el tercer dataset (*DIC-HeLa*) contiene 20 imágenes. La **metodología** consiste en una rama de codificación, la cual obtiene características de la imagen original y va reduciendo su tamaño, y una rama de expansión, en la cual se utiliza una convolución inversa para expandir la imagen y combinar la información espacial con las características obtenidas. Para los dos últimos datasets se utilizó aumento de datos para hacer más robusto el modelo. Los **resultados** en el primer dataset, acorde a las métricas *warping error* y *rand*





*error*, fueron de 0.0003529 y 0.0382 respectivamente, para el segundo y tercer dataset se evaluó la métrica IOU, obteniendo valores del 92% y 77.5% respectivamente. En el trabajo original se especifica contra que algoritmos se probó la U-Net, la cual obtuvo los mejores resultados en todos los datasets.

**52.** (Ganesan, y otros, 2014) En este estudio se utilizan transformaciones de trazas para modelar un sistema visual humano que replicaría la forma en que un observador humano ve una imagen para poder detectar retinopatía diabética. La **metodología** empleada para clasificar las características extraídas con esta técnica, se basa en la utilización de una máquina de vectores de soporte (SVM) con núcleos de funciones de base cuadrática, polinómica, radial y red neuronal probabilística (PNN) y el algoritmo genético (GA) se utilizó para ajustar los parámetros de clasificación. El **dataset** empleado se obtuvo del Departamento de Oftalmología, Kasturba Medical College, Manipal, India. Como **resultado** se obtuvo una precisión de 99.41 y 99.12% con núcleos cuadráticos PNN-GA y SVM, respectivamente.

**53.** (Zhang, y otros, 2014) El objetivo de esta investigación es detectar automáticamente los exámenes normales en una red de teleoftalmología, reduciendo así la carga para los lectores. Dentro de la **metodología** se propusieron nuevos métodos de preprocesamiento, que realizan no solo tareas de normalización y eliminación de ruido, sino que también detectan reflejos y artefactos en la imagen, además de un nuevo método de segmentación de candidatos, basado en la morfología matemática, así es como estos candidatos se caracterizan por usar características clásicas, pero también características contextuales novedosas. Finalmente, se utiliza un algoritmo forestal aleatorio para detectar los exudados entre los candidatos. El **dataset** utilizado es una base de datos clínica llamada e-ophtha EX, que contiene exudados contorneados con precisión manualmente. El **resultado** de este método ha sido validado en la base de datos e-ophtha EX, obteniendo un AUC de 0.95. También se ha validado en otras bases de datos, obteniendo un AUC entre 0,93 y 0,95, superando a los métodos más avanzados.

**54.** (Eswaran, Saleh, & Abdullah, 2014) Este artículo presenta un algoritmo para la segmentación de exudados automatizados de imágenes de fondo de color. La **metodología** comprende dos etapas principales, a saber, preprocesamiento y segmentación. Se emplea un novedoso método de preprocesamiento para la eliminación del fondo a través de la mejora del contraste y la eliminación del ruido. En la segunda etapa, la imagen preprocesada se corta horizontal y verticalmente en una serie de sectores y luego se obtienen los valores de proyección correspondientes para seleccionar un valor umbral apropiado para cada uno de los sectores de la imagen. Finalmente, se extrae el disco óptico para facilitar la identificación correcta de los exudados y disminuir los casos de falsos positivos. El **dataset** DIARETDB1 se utiliza para medir la precisión del método propuesto. Sobre la base de los experimentos que se llevan a cabo en píxeles, se encuentra que el **resultado** con el algoritmo propuesto logra mejores resultados en comparación con los algoritmos conocidos. Con el algoritmo propuesto, se obtienen valores promedio de 71.2%, 72.77%, 99.98%, 97.72%, 99.74% y 83.28% en términos de superposición, sensibilidad, especificidad, PPV, precisión y coeficiente kappa respectivamente.

**55.** (Akram, Khan, Iqbal, & Butt, 2010) La localización y detección automatizadas del disco óptico (OD) es un paso esencial en el análisis de los sistemas digitales de retinopatía diabética. En este artículo, se propone un sistema automatizado para la localización y detección de discos ópticos. La **metodología** empleada localiza el disco óptico usando un filtro y umbral promedio, extrae la región de interés (ROI) que contiene el disco óptico para ahorrar tiempo y detecta el límite del disco óptico usando Hough transform. Este método se puede usar en el análisis computarizado de imágenes de la retina, por ejemplo, en el cribado automático de la retinopatía diabética. La técnica se prueba en



**datasets** DRIVE, STARE, diaretdb0 y diaretdb1 de imágenes etiquetadas manualmente que se han establecido para facilitar estudios comparativos sobre localización y detección de disco óptico en imágenes retinianas. El método propuesto logra como **resultado** una precisión promedio de 96.7% para la localización y un área promedio bajo la curva característica operativa del receptor de 0.958 para detección óptica.

## Referencias

- Chen, Y., Duan, W., Sehrawat, P., Chauhan, V., Alfaro, F., Gavrieli, A., . . . Dai, W. (2018). Improved perfusion pattern score association with type 2 diabetes severity using machine learning pipeline: Pilot study. *Journal of Magnetic Resonance Imaging*, 834-844.
- Abbas, Q., Fondon, I., Sarmiento, A., Jiménez, S., & Alemany, P. (2017). Automatic recognition of severity level for diagnosis of diabetic retinopathy using deep visual features. *Medical & Biological Engineering & Computing*, 1959–1974.
- Abdullah, A., Gayathri, N., Selvakumar, S., & Kumar, S. R. (2018). Identification of the Risk Factors of Type II Diabetic Data Based Support Vector Machine Classifiers upon Varied Kernel Functions. In *Computational Vision and Bio Inspired Computing. Lecture Notes in Computational Vision and Biomechanics*, vol 28. (pp. 496-505). Springer, Cham.
- Acevedo, A., Alférez, S., Merino, A., Puigvi, L., & Rodellar, J. (2019). Recognition of peripheral blood cell images usinf convolutional neural networks. *Computer Methods and Programs in Biomedicine*.
- Acharya, U. R., Fujita, H., Oh, S. L., Hagiwara, Y., Tan, J. H., Adam, M., & Tan, R. S. (2018). Deep Convolutional Neural Network for the Automated Diagnosis of Congestive Heart Failure Using ECG Signals. *Applied Intelligence*, .
- Acharya, U. R., Fujita, H., Oh, S. L., Raghavendra, U., Tan, J. H., Adam, M., . . . Hagiwara, Y. (2018). Automated identification of shockable and non-shockable life-threatening ventricular arrhythmias using convolutional neural network. *Future Generation Computer Systems*, 952-959.
- Acharya, U. R., Oh, S. L., Hagiwara, Y., Tan, J. H., Adeli, H., & Subha, D. P. (2018). Automated EEG-based screening of depression using deep convolutional neural network. *Computer Methods and Programs in Biomedicine*, 103-113.
- Adam, M., Ng, E. Y., Oh, S. L., Heng, M. L., Hagiware, Y., Tan, J. H., . . . Acharya, U. R. (2018). Automated characterization of diabetic foot using nonlinear features extracted from thermograms. *Infrared Physics & Technology*, 89, 325-337.
- Akram, M., Khan, A., Iqbal, K., & Butt, W. H. (2010). Retinal Images: Optic Disk Localization and Detection. *International Conference Image Analysis and Recognition*, 40-49.
- Al-Dulaimi, K., Al-Saabawi, A., & Resen, R. (2019). Using Adapted JSEG Algorithm with Fuzzy C Mean for Segmentation and Counting of White Blood Cell and Nuleus Images. *Asia-Pacific Conference on Computer Science and Data Engineering*.



- Alom, M., Yakopcic, C., Taha, T., & Asari, V. (2018). Nuclei Segmentation with Recurrent Residual Convolutional Neural Networks based U-Net (R2U-Net). *IEEE National Aerospace and Electronics Conference*.
- Biswas, M., Kuppili, V., Saba, L., Edla, D. R., Suri, H., Sharma, A., . . . Suri, J. (2019). Deep learning fully convolution network for lumen characterization in diabetic patients using carotid ultrasound: a tool for stroke risk. *Medical & Biological Engineering & Computing*, 543–564.
- Cahn, A., Shoshan, A., Sagiv, T., Yesharim, R., Goshen, R., Shalev, V., & Raz, I. (2020). Prediction of progression from pre-diabetes to diabetes: Development and validation of a machine learning model. *Diabetes Metabolism Research and Review*.
- Cogil, S., & Wang, L. (2016). Support vector machine model of developmental brain gene expression data for prioritization of Autism risk gene candidates. *Bioinformatics*, 32(23), 3611-3618.
- Dasgupta, A., & Singh, S. (2017). A Fully Convolutional Neural Network based Structured Prediction Approach Towards the Retinal Vessel Segmentation. *2017 IEEE 14th International Symposium on Biomedical Imaging* (págs. 248-251). .: IEEE.
- de Lima, M. D., Roque e Lima, J., & Barbosa, R. (2020). Medical data set classification using a new feature selection algorithm combined with twin-bounded support vector machine. *Medical & Biological Engineering & Computing*, 1–10.
- Esteva, A., Kuprel, B., Novoa, R., Ko, J., Swetter, S., Blau, H., & Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 115-118.
- Eswaran, C., Saleh, M., & Abdullah, J. (2014). Projection Based Algorithm for Detecting Exudates in Color Fundus Images. *Proceedings of the 19th International Conference on Digital Signal Processing*, 459-463.
- Fan, H., Zhang, F., Xi, L., Li, Z., Liu, G., & Xu, Y. (2019). LukocyteMask: An automated localization and segmentation method for leukocyte in blood smear images using deep neural networks. *Jornal of Biophotonics*.
- Ganesan, K., Martis, R. J., Acharya, U. R., Chua, C. K., Min, L. C., Ng, E., & Laude, A. (2014). Computer-aided diabetic retinopathy detection using trace transforms on digital fundus images. *Medical & Biological Engineering & Computing*, 663-672.
- Giannakakis, G., Trivizakis, E., Tsiknakis, M., & Marias, K. (2019). A novel multi-kernel 1D convolutional neural network for stress recognition from ECG. *2019 8th International Conference on Affective Computing and Intelligent Interaction Workshops and Demos (ACIIW)* (pp. 273-276). .: IEEE.
- Gill, N., & Mittal, P. (2016). A computational hybrid model with two level classification using SVM and neural network for predicting the diabetes disease. 1-10.
- Gu, Z., Cheng, J., Fu, H., Zhou, K., Hao, H., Zhao, Y., . . . Liu, J. (2019). CE-Net: Context Encoder Network for 2D Medical Image Segmentation. *IEEE transactions on medical imaging*, 2281,2292.



- Haenssle, H., Fink, C., Schneiderbauer, R., Toberer, F., Buhl, T., Blum, A., . . . Uhlmann, L. (2018). Man against machine: diagnostic performance of a deep learning convolutional neural network for dermoscopic melanoma recognition in comparison to 58 dermatologists. *Annals of Oncology*, 1836-1842.
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. *IEEE Conference on Computer Vision and Pattern Recognition*.
- Ibtehaz, N., & Rahman, M. (2019). MultiResUnet: Rethinking the U-Net Architecture for Multimodal Biomedical Image Segmentation. *ArXiv*.
- Jia, F., Liu, J., & Tai, X.-c. (2019). A Regularized Convolutional Neural Network for Semantic Image Segmentation. *arXiv*.
- Kang, E., Min, J., & Ye, J. C. (2017). A deep convolutional neural network using directional wavelets for low-dose X-ray CT reconstruction. *Medical Physics*, e360-e375.
- Kaur, M., & Kaur, M. (2015). A hybrid approach for automatic exudates detection in eye fundus image.
- Kim, J., Kim, J., Kwak, M. J., & Baja, M. (2017). Genetic prediction of type 2 diabetes using deep neural network. *Clinical Genetics*, 822-829.
- Marin, D., Gegundez-Arias, M., Ponte, B., Alvarez, F., Garrido, J., Ortega, C., . . . Bravo, J. (2018). An exudate detection method for diagnosis risk of diabetic macular edema in retinal images using feature-based and supervised classification. *Medical & Biological Engineering & Computing*, 1379–1390.
- McKearney, R., & MacKinnon, R. (2019). Objective auditory brainstem response classification using machine learning. *International Journal of Audiology*, 1-8.
- Milletari, F., Navab, N., & Ahmadi, S.-A. (2016). V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation. *Fourth International Conference on 3D vision*, 565,571.
- Mohsen, H., El-Dahshan, E. S., El-Horbaty, E. S., & Salem, A. B. (2018). Classification using deep learning neural networks for brain tumors. *Future Computing and Informatics Journal*, 68-71.
- Muthu Rama, K. M., Acharya, U. R., Chandran, V., Martis, R. J., Tan, J. H., Koh, J. E., . . . Laude, A. (2015). Application of higher-order spectra for automated grading of diabetic maculopathy. *Medical & Biological Engineering & Computing*, 1319-1331.
- Nakajima, K., Kudo, T., Nakata, T., Kiso, K., Kasai, T., Taniguchi, Y., . . . Edenbrandt, L. (2017). Diagnostic accuracy of an artificial neural network compared with statistical quantitation of myocardial perfusion images: a Japanese multicenter study. *European Journal of Nuclear Medicine and Molecular Imaging*, 2280-2289.
- Naranjo, L., Pérez, C. J., Martín, J., & Campos-Roca, Y. (2017). A two-stage variable selection and classification approach for Parkinson's disease detection by using voice recording replications. *Computer Methods and Programs in Biomedicine*, 142, 147-156.
- Parmar, R., Lakshmanan, R., Purushotham, S., & Soundrapandiyan, R. (2019). Detecting Diabetic Retinopathy from Retinal Images Using CUDA Deep Neural Network. In A. K. Sangaiah , S. Shantharajah, & P.



Theagarajan, *Intelligent Pervasive Computing Systems for Smarter Healthcare* (pp. 379-394). USA: John Wiley & Sons Inc.

- Prakash, N., Hemalakshmi, G., & Mary, M. (2016). Automated grading of diabetic retinopathy stages in fundus images using. *Journal of Chemical and Pharmaceutical Research*, 537-541.
- Rajpurkar, P., Hannun, A. Y., Haghpanahi, M., Bourn, C., & Ng, A. Y. (2017). Cardiologist-level arrhythmia detection with convolutional neural networks. *arXiv preprint arXiv:1707.01836*, .
- Ramachandran, N., Hong, S. C., Sime, M., & Wilson, G. (2017). Diabetic retinopathy screening using deep neural network. *Clinical & Experimental Ophthalmology*, 412-416.
- Rinkel, W., van der Oest, M., & Coert, J. (2020). Item reduction of the 39-item Rotterdam Diabetic Foot Study Test Battery using decision tree modeling. *Diabetes Metabolism Research and Reviews*.
- Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. *Medical Image Computing and Computer-Assisted Intervention*, 234, 241.
- Sengür, A., Akbulut, Y., Budak, Ü., & Cömer, Z. (2019). White Blood Cell Classification Based on Shape and Deep Features. *International Artificial Intelligence and Data Processing Symposium*.
- Smitha, M., Nisa, A., & Archana, K. (2018). Diabetic Retinopathy Detection in Fundus Image Using Cross Sectional Profiles and ANN. In *Computational Vision and Bio Inspired Computing vol 28* (pp. 982-993). Springer, Cham.
- Spanhol, F. A., Oliveira, L. S., Petitjean, C., & Laurent, H. (2016). A Dataset for Breast Cancer Histopathological Image Classification. *IEEE Transactions on Biomedical Engineering*, 63(7), 1455-1462.
- Tan, J. H., Acharya, U. R., Bhandary, S. V., Chua, K. C., & Sivaprasad, S. (2017). Segmentation of optic disc, fovea and retinal vasculature using a single convolutional neural network. *Journal of Computational Science*, 70-79.
- Tan, J. H., Fujita, H., Sivaprasad, S., Bhandary, S. V., Rao, A. K., Chua, K. C., & Acharya, U. R. (2017). Automated segmentation of exudates, haemorrhages, microaneurysms using single convolutional neural network. *Information Sciences*, 66-76.
- Wollmann, T., Gunkel, M., Chung, I., Erfle, H., Rippe, K., & Rohr, K. (2019). GRUU-Net: Integrated convolutional and gated recurrent neural network for cell segmentation. *Medical Image Analysis*, 68,79.
- Xheng, X., Wang, Y., Guang, G., & Liu, J. (2018). Fast and robust segmentation of white blood cell images by self-supervised learning. *Micron*.
- Xia, X., & Kulis, B. (2017). W-Net: A Deep Model for Fully Unsupervised Image Segmentation. *ArXiv*.
- Zeng, Y., Chen, X., Zhang, Y., Bai, L., & Han, J. (2018). Dense-U-Net: densely connected convolutional network for semantic segmentation with a small number of samples. *Tenth International Conference on Graphic and Image Processing*.





- Zeng, Z., Xie, W., Zhang, Y., & Lu, Y. (2019). RIC-Unet: An Improved Neural Network Based on Unet for Nuclei Segmentation in Histology Images. *IEEE Access*.
- Zhang, X., Thibault, G., Decenci re, E., Marcotegui, B., La , B., Danno, R., . . . Erginay, A. (2014). Exudate detection in color retinal images for mass screening of diabetic retinopathy. *Medical Image Analysis*, 1026-1043.
- Zhou, X., Wang, C., Li, Z., & Zhang, F. (2019). Adaptative Histogram Thersholding-based for Leukocyte Segmentation. In *Advances in Intelligent Information Hiding and Multimedia Signal Processing* (pp. 451,459). Jilin, China: Springer.